

Dokumentacja specyfikacji wymagań

Spis Treści:

1. Wprowadzenie.....	1
2. Cele systemu.....	1
a. Wczytywanie danych i preparacja danych.....	2
b. Analiza częstości słów i analiza sentymentu.....	2
c. TF-IDF.....	2
d. Klasyfikacja.....	2
4. Wymagania niefunkcjonalne.....	3
a. Wydajność i niezawodność.....	3
b. Kompatybilność.....	3
c. Powtarzalność i skalowalność.....	3
5. Interfejsy użytkownika i wymagania dotyczące danych.....	3
a. Interfejsy użytkownika.....	3
b. Dane źródłowe.....	3
c. Dane wyjściowe.....	4
6. Słownictwo dokumentacji.....	5
7. Przypadki użycia (use cases).....	6
8. Scenariusze użytkownika (user stories).....	7

1. Wprowadzenie

Nie od dziś wiadomo, że decyzje podejmowane przez FED w sprawie stóp procentowych wpływają na ceny akcji amerykańskich spółek. W internecie od dawna krąży teoria według której da się przewidzieć wzrost/spadek stóp procentowych, tylko na podstawie tylko czy przewodniczący Fed zacznie przemówienie od “good morning” czy bardziej codziennego “Hello”. Postanowiliśmy sprawdzić, czy można takie przewidywania prowadzić na podstawie wypowiedzi przewodniczących FED, korzystając z technik poznanych podczas zajęć z projektowania systemów informatycznych.

2. Cele systemu

Głównym celem systemu jest automatyczna klasyfikacja przemówień prezesów FED pod kątem przewidywanego kierunku polityki monetarnej. System ocenia, czy dany tekst ma wydźwięk gołębi (zwiastujący obniżki stóp), czy jastrzębi (zwiastujący podwyżki stóp), przypisując mu ostatecznie jedną z dwóch etykiet: „luzowanie” lub „zacieśnianie”. W procesie przypisywania etykiety użyjemy poznanych podczas zajęć technik, takich jak analiza częstości słów, analiza sentymentu, macierz tfidf i klasyfikacja. Celem naszej analizy będzie sprawdzenie, jakie słowa / sentyment wiąże się z jakimi zmianami stóp, oraz sprawdzenie czy nasz system jest w stanie efektywnie przewidywać kierunek zmian, bazując na wczytanym tekście. Założenie jest takie, że jeśli sentyment w danym przemówieniu jest negatywny, FED w najbliższym czasie będzie obniżał stopę procentową, aby wesprzeć gospodarkę i vice versa.

3. Wymagania funkcjonalne

a. Wczytywanie danych i preparacja danych

- i. System powinien wczytywać dane w formacie csv. W pliku csv dane powinny być posortowane w kolumnach: numer przemówienia, tekst przemówienia, kierunek polityki FED po przemówieniu.
- ii. System powinien usuwać “stop words”, i inne słowa potencjalnie zakłócające wynik analizy
- iii. System powinien przeprowadzić *stemming* otrzymanego tekstu.

b. Analiza częstości słów i analiza sentymentu

- i. System powinien przeprowadzać analizę sentymentu na podstawie wszystkich tekstów w pliku csv.
- ii. System powinien przeprowadzać analizę sentymentu na podstawie słownika sentymentu odpowiedniego do tekstów o tematyce ekonomicznej (Loughran-McDonald).
- iii. System powinien generować zestawienie (wykres) słów nacechowanych emocjonalnie, które najczęściej pojawiają się w raportach, z podziałem na wydźwięk pozytywny i negatywny.

c. TF-IDF

- i. System powinien dokonać wektoryzacji korpusu tekstowego, tworząc macierz TF-IDF i filtrując rzadko występujące terminy.
- ii. System powinien połączyć wektory TF-IDF z wynikami analizy sentymentu, tworząc jednolitą bazę cech dla algorytmu uczącego.
- iii. System powinien generować globalną chmurę słów (Word Cloud) ilustrującą tokeny o najwyższej wadze TF-IDF w całym zbiorze dokumentów.

d. Klasyfikacja

- i. System powinien samodzielnie zaklasyfikować analizowane przemówienia do jednej z dwóch polityk systemowych: „luzowanie” lub „zacieśnianie”.
- ii. System powinien wytworzyć macierz pomyłek (Confusion Matrix) dla przeprowadzonej klasyfikacji przy użyciu metody walidacji krzyżowej (5-Fold CV), porównując predykcje z danymi historycznymi.
- iii. System powinien wyliczyć i zaprezentować na wykresie kluczowe metryki jakości modelu, takie jak dokładność, precyzja, czułość, specyfika oraz wynik F1.

4. Wymagania niefunkcjonalne

- a. Wydajność i niezawodność
 - i. Przetwarzanie pliku csv o rozmiarze nie większym niż 50MB powinno przebiegać poniżej 10 sekund
 - ii. System nie powinien “crashować” się podczas działania.
- b. Kompatybilność
 - i. System powinien działać na urządzeniach z system operacyjnym Windows, Linux i MacOS
 - ii. Użytkownik powinien móc wygenerować raport bazując na załączonych danych, lub swoich własnych.
- c. Powtarzalność i skalowalność
 - i. System powinien generować takie same wyniki dla takich samych danych wejściowych, nawet jeżeli będzie uruchamiany w różnych środowiskach. (Reproducible Research)
 - ii. System powinien poprawnie przetworzyć każdy plik csv w odpowiednim formacie, jeżeli jego rozmiar nie przekracza 50MB.

5. Interfejsy użytkownika i wymagania dotyczące danych

a. Interfejsy użytkownika

Z uwagi na relatywną prostotę systemu, nie przewidujemy używania interfejsu graficznego. Wybór pliku csv do analizy należy wykonać w kodzie źródłowym projektu (poprzez zwykłe zmienienie nazwy pliku w linijce kodu *patrz: Dane źródłowe*). Spodziewamy się, że użytkownik końcowy będzie uruchamiał kod w Rstudio (lub innym podobnym programie), w którym wygenerowane przez system wykresy będzie mógł pobrać na swój komputer.

b. Dane źródłowe

W repozytorium GitHub załączamy plik o rozszerzeniu .csv, na którym dokonano analizy. Użytkownik może zmienić plik, na którym pracuje kod, poprzez zmienienie nazwy w cudzysłowie z “przemowienia_fed.csv” na “<inna nazwa>.csv”, gdzie <inna nazwa>

powinna być zastąpiona nazwą pliku użytkownika. Plik powinien być w formacie csv, z kolumnami opisanymi kolejno: *id_przemowienia*, *tekst_przemowienia*, *kierunek_polityki*. Każdy z wierszy danych wejściowych powinien mieć kolejno: id przemówienia (jego kolejność w tabeli, zaczynając od 1), tekst przemówienia, i kierunek polityki, którą FED faktycznie podjęło po tym przemówieniu (luzowanie lub zacieśnianie).

c. Dane wyjściowe

Po zakończeniu procesu, system automatycznie generuje i zwraca następujące dane wyjściowe w formie graficznej:

1. **Macierz pomyłek klasyfikatora (Confusion Matrix):** Wykres kafelkowy ilustrujący zestawienie predykcji modelu SVM z historycznymi danymi rzeczywistymi (liczba decyzji trafionych i błędów).
2. **Wykres wydajności modelu:** Prezentacja najważniejszych metryk walidacji krzyżowej algorytmu, tj. dokładności, precyzji, czułości, specyfiki oraz wyniku F1.
3. **Zestawienie słów sentymentu:** Wykres kolumnowy przedstawiający Top 10 najczęstszych tokenów podzielonych na wydźwięk pozytywny i negatywny, oparty na analizie dedykowanym słownikiem finansowym (Loughran-McDonald).
4. **Globalna Chmura Słów (Word Cloud):** Graficzna reprezentacja kluczowego słownictwa z korpusu, w której rozmiar słowa jest proporcjonalny do jego ważności obliczonej algorytmem TF-IDF.

6. Słownictwo dokumentacji

Poniżej przedstawiamy słowniczek specjalistycznych słów użytych w dokumentacji:

FED - (z ang. Federal Reserve Board) - System Rezerw Federalnych. Pełni funkcję Banku Centralnego Stanów Zjednoczonych.

Polityka gołębia (ang. “dovish”) - polityka stymulacji wzrostu gospodarczego, powiązana z obniżaniem stóp procentowych.

Polityka jastrzębia (“hawkish”) - polityka intensywnej walki z inflacją poprzez podnoszenie i utrzymywanie wysokich stóp procentowych.

Analiza sentymentu - proces identyfikacji i kategoryzacji emocji lub opinii wyrażonych w tekście jako pozytywne, negatywne lub neutralne.

Klasyfikacja - metoda uczenia maszynowego polegająca na przypisywaniu danych wejściowych do określonych, zdefiniowanych wcześniej kategorii.

Macierz TF-IDF - technika statystyczna służąca do oceny ważności słowa w dokumencie w odniesieniu do całego zbioru, uwzględniająca częstość występowania słowa oraz jego unikalność.

Macierz pomyłek - narzędzie w formie tabeli używane do oceny jakości modelu klasyfikacyjnego, pokazujące zestawienie przewidywań modelu z faktycznymi danymi.

Stemming - technika przetwarzania języka polegająca na sprowadzaniu słów do ich podstawowego rdzenia (tematu) poprzez usuwanie końcówek fleksyjnych.

Stop words - słowa o bardzo dużej częstości występowania, które nie niosą istotnych informacji merytorycznych i są zazwyczaj usuwane w procesie analizy tekstu.

RStudio - zintegrowane środowisko programistyczne (IDE) przeznaczone do pracy z językiem R, służące do analizy statystycznej i wizualizacji danych.

Walidacja krzyżowa (Cross-Validation / 5-Fold CV) – technika oceny i trenowania modelu uczenia maszynowego. Polega na podziale zbioru danych na części (w tym projekcie na 5), naprzemiennym uczeniu i testowaniu modelu, co zapobiega zjawisku przeuczenia (overfittingu).

Korpus (Corpus) – ustrukturyzowany zbiór dokumentów tekstowych (w tym przypadku przemówień prezesów FED), przygotowany i oczyszczony w pamięci programu w celu przeprowadzenia zautomatyzowanej analizy lingwistycznej.

7. Przypadki użycia (use cases)

Użytkownik:

- Otwiera skrypt źródłowy (np. w RStudio) w obszarze roboczym zawierającym plik wejściowy.
- Instaluje (jeśli to konieczne) i wczytuje wymagane pakiety biblioteczne.
- Wskazuje plik wejściowy w kodzie i uruchamia skrypt.
- Analizuje wygenerowany raport HTML oraz przegląda poszczególne wizualizacje.
- Zapisuje wybrane wykresy i macierze na swój dysk lokalny za pomocą wbudowanych narzędzi interfejsu.

Skrypt:

- Przetwarza tekst
- Oczyszcza tekst z stop-słów
- Oczyszcza tekst z innych słów, nie wnoszących nic do analizy
- Przeprowadza wektoryzację tekstu (macierz TF-IDF) oraz generuje globalną chmurę słów (Word Cloud).
- Analizuje sentyment korpusu i generuje zestawienie najczęstszych tokenów emocjonalnych.
- Trenuje model uczenia maszynowego (klasyfikator SVM) z wykorzystaniem 5-krotnej walidacji krzyżowej (5-Fold CV).
- Generuje macierz pomyłek dla przeprowadzonej klasyfikacji oraz wykres słupkowy prezentujący kluczowe wskaźniki wydajności modelu.

Testowe przypadki użycia:

- Test z plikiem .csv zawierającym tylko jedno przemówienie
- Test z plikiem .csv zawierającym kilka przemówień
- Test z plikiem .csv zawierającym wyłącznie przemówienia, po których była prowadzona polityka “gołębia”

- Test z plikiem .csv zawierającym wyłącznie przemówienia, po których była prowadzona polityka “jastrzębia”
- Test z plikiem .csv zawierającym przemówienia, po których były prowadzone obie polityki.

8. Scenariusze użytkownika (user stories)

Scenariusz 1

Jako: Analityk finansowy

Chcę: Szybko analizować sentyment przemówień prezesów FED i przewidzieć politykę monetarną FED w najbliższym czasie

Aby: Ocenic ogólny sentyment wypowiedzi bez konieczności czytania całego tekstu przemówienia

Kryteria akceptacji:

- System wczytuje tekst w formacie csv
- Wynik analizy jest przypisany do jednej z kategorii: “luzowanie” lub “zacieśnianie”

Scenariusz 2

Jako: Inwestor giełdowy

Chcę: aby algorytm oceniał, w jakim stopniu komunikacja banku centralnego przekłada się na ostateczne decyzje

Aby: Móc dynamicznie dostosowywać swoją strategię inwestycyjną

Kryteria akceptacji:

- Model przewiduje jeden z dwóch kierunków polityki
- Model ma dokładność powyżej 70%

Scenariusz 3

Jako: Menedżer portfela inwestycyjnego

Chcę: Analizować możliwy kierunek polityki FED, na podstawie byłych przemówień prezesów FED

Aby: skuteczniej oceniać długoterminową politykę FED i dostosowywać swoje portfolio

Kryteria akceptacji:

- System wczytuje wiele przemówień w formacie csv
- System generuje analizę sentymentu dla tych przemówień
- System szybko generuje analizę, nawet pomimo wielu wczytanych przemówień